Kaggle American Express – Default Prediction

Daniel_WJ

Discussion

목표

Discussions 의 내용을 이해하는 것을 통해 데이터와 모델 개선에 도움을 얻는 정보를 얻는다.

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- 모든 float 유형 열에는 각 열에 [0, 0.01]의 무작위 균일 노이즈가 추가된다.
 - => 정수 유형의 열을 찾을 수 있다.
 - => https://www.kaggle.com/code/raddar/the-data-has-random-uniform-noise-added
- 188개의 실수/범주 자료형이 있다.

95개의 np.int8/np.int16 자료형.

93개의 np.float32 유형

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- 정리된 데이터 셋을 다음 데이터 셋에서 찾을 수 있다.
 - => https://www.kaggle.com/datasets/raddar/amex-data-integer-dtypes-parquet-format

- 데이터 변환에 사용되는 노트북
 - => https://www.kaggle.com/code/raddar/amex-data-int-types-train
 - => https://www.kaggle.com/code/raddar/amex-data-int-types-test

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- S_13, S_11은 이미 정수로 변환되었다.
 - => train['S 11']은 15,16,17 값이 존재한다.
- 해당 데이터를 이용하여 0.792 -> 0.794로 향상시켰다.
 - => https://www.kaggle.com/code/cdeotte/xgboost-starter-0-793
 - => R_26은 0.2이하의 유일한 값이 548160이 있다. 그러나 실제로 확인 결과 노이즈가 추가된 6개의 구분된 값이었다. 그래서 int8로 변환이 가능하였다.

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- B_19, S_8, S_13은 정수로 변환하였다.
 - => train['S_11']은 15,16,17 값이 존재한다.
- B_4 도 임의의 랜덤 값이 추가된 것 같다.
- 작성자의 EDA 링크
 - => https://www.kaggle.com/code/raddar/the-data-has-random-uniform-noise-added

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- 데이터 전처리에 np.nanmean을 사용하였다.

I don't use cudf - useless for this competition. as for how to assign NA is actually the problem itself. I am using np.nanmean and other similar numpy aggregate funcs

- 코드에서 cudf의 NA를 위해 -1을 모든 것을 변환.

The following code will convert all -1 to NA in cudf for c in df.columns:

df.loc[df[c]==-1,c] = cudf.NA

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- Parquet vs pickle



=> Parquet가 사이즈 측면에서 효율적이다.

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/328514

- B_8, D_112, B_18는 정수형 변수

Carlos A. S. de Souza • (2612th in this Competition) • 2 months ago



Hello raddar! I think that another 4 variables could be squeezed into the **int** type as well: **D104,D_112,B_8 and B_18 ** (look at the histograms of Version 16 of this notebook.

B_18 seems like a counting variable (Versions 14 and 15 of the same notebook above), while D_104,D_112 and B_8 seems like binary variables.

raddar Topic Author + (29th in this Competition) + 2 months ago

For D_104 and D_112, the noise seems to be random, although not in an uniform or normal way (distribution). For B_8, the noise seems to be pretty uniform around 1.



Nice analysis. However, all your listed variables are not 100% certainly integer types. For example D_104 over 0.9 shows "normal" like distribution, which indicates that the values are definetly not integers. same goes for other variables - there are ranges where non-uniform distribution can be seen.

B_18 is most likely integer type - however for me it was impossible to reverse engineer it.

The data has uniform random noise injected

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327649

데이터는 균일한 랜덤 노이즈가 주입되었다.

https://www.kaggle.com/raddar/the-data-has-random-uniform-noise-added

The data has uniform random noise injected

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327651

데이터는 노이즈가 실수형에 [0, 0.01] 랜덤한 노이즈가 추가되어 있다.

데이터 노이즈를 제거한 데이터 셋

https://www.kaggle.com/datasets/raddar/amex-data-integer-dtypes-parquet-format

The data has uniform random noise injected

https://www.kaggle.com/competitions/amex-default-prediction/discussion/332574

8/1일 작성

D_39의 변수에 대한 분석

https://www.kaggle.com/code/raddar/deanonymized-days-overdue-feat-amex

Understanding NA in the dataset

https://www.kaggle.com/competitions/amex-default-prediction/discussion/331725

2022/06 작성

NA에 대해 분석한 내용에 대한 작성

https://www.kaggle.com/code/raddar/understanding-na-values-in-amex-competition/notebook

Summary: Basic pipeline for tabular competition for beginner!

https://www.kaggle.com/competitions/amex-default-prediction/discussion/331840

2022/06 작성


초보자가 정형 대회를 위한 여러가지 단계별 작업 내용 정리

- 01. 데이터 보기 + 데이터 전처리: EDA, 데이터 정리, 정보 손실 없이 데이터 크기 줄이기
- 02. 피처 엔지니어링

LB기능을 향상 시키기 위한 피처 엔지니어링

- 03. 피처 선택(Feature Selection)
- 04. 베이스 라인 모델링 및 하이퍼 파라미터 최적화
- 05. 앙상블 모델 가중치 및 평균 앙상블, 스태킹 모델

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327464




ROC 곡선

진한 빨간색 곡선

AUC

곡선 아래 영역 – 밝은 빨간색 부분 녹색선은 4%의 긍정적인 예측.


https://www.kaggle.com/competitions/amex-default-prediction/discussion/327464



대회의 평가지표

- (1) 정규화된 지니계수 단순히 확장된 AUC이다.
- (2) 4%에 캡쳐된 기본 비율

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327464




대회의 평가지표

(1) 정규화된 지니계수 – 단순히 확장된 AUC이다.

값의 범위는 -1~1 사이. 2 * AUC - 1

(2) 4%에 캡쳐된 기본 비율

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327464



대회의 평가지표


(1) 정규화된 지니계수 – 단순히 확장된 AUC이다.

값의 범위는 -1~1 사이. 2 * AUC - 1

(2) 4%에 캡쳐된 기본 비율

총 샘플 수의 4%로 설정된 임계 값에 대한 참 양성 비율. 녹색선과 빨간색 ROC 곡선 사이의 교차점의 y좌표에 해당. 값의 범위는 0~1 사이.

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327464



대회의 평가지표

- (1) 정규화된 지니계수(G)
- (2) 4%에 캡쳐된 기본 비율(D)

$$M = 0.5 * (G + D)$$

두 평가지표의 평균. 곡선 아래의 큰 빨간색 영역과 녹색 선과의 높은 교차점을 동시에 최적화하기

Understanding competition metric step by step

https://www.kaggle.com/competitions/amex-default-prediction/discussion/333338

평가 지표에 대한 자세한 설명.

Let's catchup with all the learnings so far

https://www.kaggle.com/competitions/amex-default-prediction/discussion/328565

여러가지 노트북의 유용한 링크 정리

DART algorithm explained

https://www.kaggle.com/competitions/amex-default-prediction/discussion/334670

DART 알고리즘의 설명.

Speed Up XGB, CatBoost, and LGBM by 20x

https://www.kaggle.com/competitions/amex-default-prediction/discussion/328606

CatBoost GPU

Kaggle jupyter 노트북에서 가속기를 GPU로 선택하고, 다음으로 분류기를 생성할 때, task_type='GPU'를 추가.

clf = CatBoostClassifier(iterations=5000, random_state=22, task_type = 'GPU')

8시간 아닌 25분으로 속도 향상.

Speed Up XGB, CatBoost, and LGBM by 20x

https://www.kaggle.com/competitions/amex-default-prediction/discussion/328606

▶ 메모리 줄이기

Kaggle 노트북에서 실행 시, 노트북 메모리 오류가 발생하지 않도록, 메모리 사용을 최적화 해야 한다. 메모리 오류를 방지하기 위해 다음의 각 K-fold의 for문 끝에 다음의 코드 추가.

import gc
del clf, tr_x, val_x, tr_y, val_y, preds, preds_test
gc.collect()

Speed Up XGB, CatBoost, and LGBM by 20x

https://www.kaggle.com/competitions/amex-default-prediction/discussion/328606

▶ XGB를 GPU에서 사용하기

GPU에서 XGB를 사용하여 속도 향상된 모델을 사용할 수 있다.

```
xgb_parms = {
  'tree_method':'gpu_hist',
  'predictor':'gpu_predictor',
}
model = xgb.train(xgb_parms)
```

참조: https://www.kaggle.com/code/cdeotte/xgboost-starter-0-793

Parquet Format Dataset for Low Memory Use

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327138

▶ parquet 데이터 포맷으로 메모리 줄이기

데이터 셋 링크 : https://www.kaggle.com/datasets/odins0n/amex-parquet

데이터 셋 변환 결과

전체 데이터 셋: 50.31 GB -> 10.41 GB train 데이터 셋: 16.39 GB -> 3.35GB test 데이터 셋: 33.82 GB -> 6.96GB

Parquet 파일 로드를 위한 예제 노트북

https://www.kaggle.com/code/odins0n/load-parquet-files-with-low-memory/

9x Data Compression achieved with Feather

https://www.kaggle.com/competitions/amex-default-prediction/discussion/327143

▶ feather를 이용한 데이터 용량 줄이기

데이터 셋 링크 : https://www.kaggle.com/datasets/ruchi798/parquet-files-amexdefault-prediction

Data	Size of csv file	Size of parquet file	Size of feather file
train_data	16.4 GB	6.7 GB	1.8 GB
test_data	33.8 GB	13.7 GB	3.6 GB

수치형 데이터를 float16으로 변경, 범주형 데이터를 category로 변경.

Tabular Classification - Tips and Tricks

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/335892

- 01 Faster data loading with pandas.
- 02 Data compression techniques to reduce the size of data by 70%.
- 03 Optimize the memory by reducing the size of some attributes.
- 04 Use open-source libraries such as Dask to read and manipulate the data, it performs parallel computing and saves up memory space.
- 05 Use cudf.
- 06 Convert data to parquet format.
- 07 Converting data to feather format.
- 08 Reducing memory usage for optimizing RAM.

Data exploration

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/335892

01 EDA for microsoft malware detection.

https://www.kaggle.com/code/youhanlee/my-eda-i-want-to-see-all/notebook

02 Time Series EDA for malware detection.

https://www.kaggle.com/code/cdeotte/time-split-validation-malware-0-68/notebook

03 Complete EDA for home credit loan prediction.

https://www.kaggle.com/code/codename007/home-credit-complete-eda-feature-importance/notebook

04 Complete EDA for Santader prediction.

https://www.kaggle.com/code/gpreda/santander-eda-and-prediction/notebook

05 EDA for VSB Power Line Fault Detection.

https://www.kaggle.com/code/go1dfish/basic-eda/notebook

Modeling

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/335892

XGBoost

LightGBM

CatBoost

Ensemble

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/335892

Ensemble

- Ensembling Techniques
- Blending
- Stacking
- Bagging
- Boosting

Hyperparameters Tuning

URL: https://www.kaggle.com/competitions/amex-default-prediction/discussion/335892

- 01 LGBM <u>hyperparameter tuning</u> methods.
- 02 Automated <u>model tuning</u> methods.
- 03 Parameter tuning with hyper plot.
- 04 Bayesian optimization for hyperparameter tuning.
- 05 Gpyopt <u>Hyperparameter Optimisation</u>.